三机器人中央 PPO：实际网络结构与目标输出

MR3-RL-POLICY-v1.1.0 · checkpoint-00512.pt · 共享 MLP + Actor / Critic

(a) 观察编码 Observation encoding

共享占据地图 → 512 维

固定 ROI、0.05 m 投影
已知 / 占据两通道
16 × 16 × 2 区块面积比例

三机器人状态 → 39 维

tb1 → tb2 → tb3，固定顺序
位置、朝向、速度、任务状态
相对目标、任务持续时间：3 × 13

候选目标特征 → 150 维

最多 15 个；每机最多 5 个
位置、路径代价、信息增益等
15 × 10；缺少的候选补零

拼接

701 维

(b) 可学习网络 Actor–Critic



两层共享全连接骨干；圆点为省略示意

Actor 目标评分头

Linear(128, 51)
[B, 51] → [B, 3, 17]

Critic 状态价值头

Linear(128, 1)
V(s)：每个联合状态 1 个标量

价值用于训练；不决定部署目标

(c) 规则约束与目标执行

原始 logits 不是速度，也不是目标坐标

tb1：17 槽评分

mask(s) → argmax

tb2：17 槽评分

mask(s, a_1) → argmax

tb3：17 槽评分

mask(s, a_1, a_2) → argmax

顺序约束：tb1 → tb2 → tb3
后续 mask 随已选目标变化
三组 logits 只前向计算一次

联合离散动作

(a_1, a_2, a_3)
每机 1 个选择

目标解释与验收

候选索引 → 共享图 (x, y)
或 KEEP / WAIT

Nav2 执行

坐标变换 → NavigateToPose
路径规划、避障、底盘运动

输入分解

512（地图）+ 39（机器人）+ 150（候选）= 701
Float32；固定比例缩放；无在线均值/方差更新

网络规模

共享骨干 106,368 + Actor 6,579 + Critic 129
总计 113,076 个参数；无 CNN / RNN / Attention

规则不等于神经网络

15 个候选槽 + KEEP + WAIT = 每头 17 槽
归属 / 可达性 / 冲突 / 最大参与约束在网络外计算

部署采用确定性 masked argmax；训练采用条件 Categorical 采样。地图来自已接收的观测，不向网络输入仿真真值。