中央 PPO 的训练闭环与冻结策略部署

同一观察 / 动作合同；训练更新与 Gazebo 推理是两个阶段

(a) 历史训练阶段：二维运动学 / LiDAR 训练后端，不是 Gazebo 在线训练

合法高层目标 → 受约束导航近似执行 → 新状态 s_{t+1} 与奖励 r_t

探索环境

三机器人运动与感知
更新已观测共享地图
计算奖励、终止 / 截断

统一观察与合法集合

s_t → 编码 $x_t \in \mathbb{R}^{701}$
机器人状态 + 地图 + 候选
网络外计算条件动作 mask

共享 Actor–Critic

701 → 128 → 128
Actor：3 × 17 logits
Critic：V(s_t)

条件联合采样

tb1 → tb2 → tb3
按各自前缀构造 mask
Categorical → (a_1, a_2, a_3)

反向传播 / 参数更新

奖励：观测进展与执行代价

+ 0.1 × 新观测自由面积 [m²]
− 0.005 × 时间 [s] − 0.01 × 路程 [m]
− 0.01 × 重复观测面积 [m²]
− 0.02 × 静止无进展时间 [s] + 2 × 首次完成

On-policy rollout：256 步

x_t、联合动作、实际条件 masks
旧联合 log-prob、V(s_t)
r_t、V(s_{t+1})、terminated / truncated
只用于本批 PPO 更新，不是 DQN 经验池

GAE 与价值目标

γ = 0.99，λ = 0.95
$\delta_t = r_t + \gamma(1-d)V(s_{t+1}) - V(s_t)$
优势 $\hat{A}_t$；回报目标 $\hat{R}_t = \hat{A}_t + V(s_t)$
d 为自然终止；截断保留 bootstrap

PPO 更新共享骨干与两个头

Policy clipped loss + Value loss − Entropy
minibatch 128；每批 4 epochs
Adam，learning rate = 3×10^{-4}
梯度裁剪范数 0.5；保存 checkpoint

以上为当前权重对应的 RL04 训练配置；最终采用验证选择的 checkpoint-00512.pt（继承已有受训权重后追加训练）。

联合动作概率：与实际采样时的前缀约束一致

$\pi(a \mid s) = \pi_1(a_1 \mid s, m_1) \cdot \pi_2(a_2 \mid s, m_2(a_1)) \cdot \pi_3(a_3 \mid s, m_3(a_1, a_2))$

$\log \pi(a \mid s) = \sum_i \log \pi_i$；更新时复用采样保存的条件 masks

实际优化目标

Lactor = −E[min(ρÂ, clip(ρ, 0.8, 1.2)Â)]；ρ = exp(log πnew − log πold)

Lvalue = ½ E[$(\hat{R} - V)^2$]；Ltotal = Lactor + 0.5 Lvalue − 0.01 E[$\sum_i H_i$]

(b) 当前部署阶段：固定网络只推理，不更新参数

Gazebo 三机器人

LiDAR → SLAM / 状态
真实 Nav2 反馈与地图变化

信息交付与中央状态

按实验条件直接 / Gateway / ns-3
收到的数据 → 融合与候选 → 701 维

固定 PPO + 原合法性规则

eval / no_grad；确定性 argmax
无 optimizer、无在线训练

高层目标 → 三套 Nav2

原目标验收 / TF / Action 所有权
规划、局部避障与速度控制由 Nav2 负责

联网条件下关键业务必须经过 ns-3；独立评价真值不进入 PPO。图示为软件结构与流程，不表示已证明 PPO 性能优于传统方法。